

Démarche statistique

Rémi Mahmoud

remi.mahmoud@institut-agro.fr

<https://demarche-stat-lesson.netlify.app>

Introduction

Objectifs

- Aborder les problèmes courants en analyse de données
- Argumenter le choix de procédures d'analyses
- Mettre en oeuvre une démarche d'analyse de données avec 
- Interpréter & restituer les résultats d'une analyse

On attend:

Attention



Réflexion



Participation



Evaluation:

2 CC (50%) + 1 projet (50%)

Quelques définitions (Wiki)

- **LA statistique**: discipline qui étudie les phénomènes à travers la collecte de **données**, leur traitement, leur analyse, l'interprétation et la présentation des résultats [...]. **Domaine des mathématiques + boîte à outils**. Fait partie de la **science des données**
- **LES statistiques**: type d'information obtenu en soumettant les valeurs à des opérations mathématiques.
- **L'analyse des données**: Famille de méthodes statistiques dont les principales caractéristiques sont d'être multidimensionnelles et descriptives.

▲: en anglais, *data analysis* $\Leftrightarrow$ Statistique

En résumé

La statistique s'intéresse à des jeux de données de taille raisonnable, fréquents dans vos domaines.

Les statistiques sont (utilisées) partout

 Reporterre, le média de l'écologie

Entre riches et pauvres, une différence de 5 tonnes de CO₂ chaque année

Les statistiques le prouvent : les riches polluent plus que les populations davantage modestes. Le 28 septembre, le Centre...

2 oct. 2023



 Radio France

Groupe sanguin et coronavirus, un hasard génétique

D'après une étude chinoise, les personnes de groupe sanguin O sont mieux immunisées contre le coronavirus que les autres groupes.

21 mars 2020



 Le Figaro

L'inquiétante hausse des homicides et tentatives d'homicide en France

Selon les dernières statistiques du ministère de l'Intérieur, les tentatives ont augmenté de 59% entre 2016 et 2022.

25 janv. 2024




- En cela elles sont un outil *politique*, traduisant une certaine vision du monde et à manipuler avec précaution.

Coeur de la statistique

- Avoir les *bonnes* données:
 - observations d'un phénomène
 - sont-elles représentatives ?


Ex. où renforcer l'avion ?



- Les résumer, les visualiser
- Se poser des questions:
 - Ex. pollution aux algues vertes: quelle variable utiliser ? Surface ? Masse ? Où/Quand/Comment faire des recueils ?
 - Cause / Conséquence (variété de blé / Rendement ; utilisation de phyto / diversité entomologique ; complexité du paysage)
 - Variables **explicatives** vs variable(s) **réponse(s)**

- Tous les effets ont-ils été pris en compte ?

Ex. **paradoxe de Simpson** ([Vidéo complète sur le sujet](#) de Science Etonnante)



Outil: R (moteur) / Rstudio (carrosserie)


- Gratuit/libre/multi-plateforme
- Nombreux (+++) domaines d'applications (ex. ce cours a été réalisé sous R)
- BEAUCOUP d'aide dispo

Installation:

1. Télécharger et installer le **moteur**  → <https://cran.r-project.org/>

2. Télécharger et installer la **carrosserie** 

On peut aussi dessiner avec R (mais c'est une autre histoire)



(a) Ridge




(b) Collatz

Figure 1: Pierre Casadebaig

Quelques définitions (1/2)

- **Population:** ensemble d'entités objet de l'investigation statistique
- **Individu:** élément de la population d'étude
- **Echantillon:** ensemble des individus pour lesquels des valeurs ont été observées pour les variables de l'étude
- **Variable:** descripteur ou caractère des individus de la population d'étude
- **Inférence:** décider pour une population à partir des données observées de l'échantillon



Quelques définitions (2/2)


Nature des variables:

- Qualitatives : les valeurs prises sont des *modalités*
 - nominale : pas de structure d'ordre 🚩
 - ordinale : modalités ordonnées 📊
- quantitative: les valeurs prises sont *numériques*
 - discrete ↑ 👤 🐟
 - continue 🕒 \$

Décrire les données à l'aide d'indicateurs

Soit $x_1, x_2, \dots, x_n$ une série de n valeurs d'une variable X . On peut les décrire en utilisant des indicateurs de **position** et de **dispersion** (que vous connaissez probablement)

- **moyenne**: $\bar{x} = \frac{1}{n} \sum x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$
- **médiane**: $q_{0.5}(x)$ = valeur telle que 50% des x_i ont une valeur inférieure et 50% une valeur supérieure
- **1er quartile**: $q_{0.25}(x)$ = valeur telle que 25% des x_i ont une valeur inférieure et 75% une valeur supérieure
- **3ème quartile**: $q_{0.75}(x)$ = valeur telle que 75% des x_i ont une valeur inférieure et 25% une valeur supérieure
- **quantile α** : $q_\alpha(x)$ = valeur telle que $100 \times \alpha$ % des x_i ont une valeur inférieure et $100 - 100 \times \alpha$ % une valeur supérieure
- **variance**: $s^2(x) = \hat{\sigma}^2(x) = \frac{1}{n-1} \sum (x_i - \bar{x})^2$
- **écart-type**: $s(x) = \sqrt{s^2(x)}$



Un jeu de données comme fil conducteur

L'association Air Breizh surveille la qualité de l'air et mesure la concentration de polluants comme l'ozone (O3, en $\mu g.m^{-3}$) ainsi que les conditions météorologiques comme la température, la nébulosité, le vent, etc. Durant l'été 2001, 112 données ont été relevées à Rennes.

```
1 ozone <- read.table("https://r-stat-sc-donnees.github.io/ozone.txt",header=TRUE, stringsAsFactors = TRUE)
2
3 head(ozone)
```

maxO3	T9	T12	T15	Ne9	Ne12	Ne15	Vx9	Vx12	Vx15	maxO3v	vent	pluie
87	15.6	18.5	18.4	4	4	8	0.6946	-1.7101	-0.6946	84	Nord	Sec
82	17.0	18.4	17.7	5	5	7	-4.3301	-4.0000	-3.0000	87	Nord	Sec
92	15.3	17.6	19.5	2	5	4	2.9544	1.8794	0.5209	82	Est	Sec
114	16.2	19.7	22.5	1	1	0	0.9848	0.3473	-0.1736	92	Nord	Sec
94	17.4	20.5	20.4	8	8	7	-0.5000	-2.9544	-4.3301	114	Ouest	Sec
80	17.7	19.8	18.3	6	6	7	-5.6382	-5.0000	-6.0000	94	Ouest	Pluie


Une question:

- Peut-on prévoir la concentration en ozone du lendemain pour avertir la population en cas de pic de pollution ?

Visualisation

La visualisation: pourquoi ?

- Quels points communs entre ces 4 jeux de données ?



Property	Value
Mean of X (average)	9 in all 4 XY plots
Sample variance of X	11 in all four XY plots
Mean of Y	7.50 in all 4 XY plots
Sample variance of Y	4.122 or 4.127 in all 4 XY plots
Correlation (r)	0.816 in all 4 XY plots
Linear regression	$y = 3.00 + (0.500 x)$ in all 4 XY plots

Data sets for the 4 XY plots

I		II		III		IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	5.76
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	8.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	7.26	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

Visualisation: quels choix ?

- La visualisation dépend de:
 - La nature des données (nature des variables, nb d'individus)
 - La problématique: qu'est-ce que je veux montrer ?
 - [le site data-to-viz.com](https://data-to-viz.com) permet de trouver de bonnes idées
- La visualisation permet de:
 - comprendre / explorer / vérifier les données
 - suggérer des analyses
 - *faire passer des idées*

Les graphiques sont ce qu'on retient de nombreux rapports / analyses / articles scientifiques.



Sur , le package [ggplot2](https://ggplot2.tidyverse.org/) permet de faire des visualisations allant du plus simple au plus compliqué.

GGplot - Quick tuto

The Basics of ggplot2

There are three main components that get *added* together to build up a plot.

1

ggplot()

Required: "Hey, R, I'm building a plot, and I'm using the data in the `data=` argument* to do it!"

Optional: "Here's the 'default' mappings (`mapping=aes (...)`) of specific data in that dataset and how I want to plot them – as the 'x' values or 'y' values or something else."

+

2

geom_xxx()

Required: "Give me a 'layer' of that chart as a column chart or a scatterplot, or a line chart, (or something else)."

Optional: "If I didn't give it to you above, or if I need to override some part of it, here's the specific mappings (`mapping=aes (...)`) to use for this layer, the specific data (`data=`), and some guidance on what colors to use for what."

+

3

theme()

Optional: "Here's how I actually want to *format* the visualization: which tick marks and gridlines to show and what color to make them, which axis labels to show and various font properties, etc."


** Not always the case, and not strictly required, but ggplot2 works best with data in a long format (or, at least, a tidy format). `gather()` from the `tidyr` package is your friend here.*

GGplot - Exemple: distribution d'une variable quantitative

```
1 library(ggplot2)
2
3 ggplot(ozone) # création de l'objet ggplot
```


GGplot - Exemple: distribution d'une variable quantitative

```
1 ggplot(ozone, aes(x = max03)) + # création de l'objet ggplot, en spécifiant ce qu'on veut en x  
2   geom_histogram() # ajout d'une couche HISTOGRAMME
```




GGplot - Exemple: distribution d'une variable quantitative

```
1 ggplot(ozone, aes(x = maxO3)) + # création de l'objet ggplot, en spécifiant ce qu'on veut en x
2   geom_histogram() + # ajout d'une couche HISTOGRAMME +
3   labs(title = "un joli titre", x= "un joli titre pour l'axe x")
```




GGplot - Exemple: distribution d'une variable quantitative

```
1 ggplot(ozone, aes(x = max03)) + # création de l'objet ggplot, en spécifiant ce qu'on veut en x
2   geom_histogram(bins = 20) + # ajout d'une couche HISTOGRAMME, classes plus grossières
3   labs(title = "un joli titre", x = "un joli titre pour l'axe x")
```



GGplot - Exemple: distribution d'une variable quantitative


```
1 ggplot(ozone, aes(y = maxO3)) + # création de l'objet ggplot, en spécifiant ce qu'on veut en y
2   geom_boxplot() + # ajout d'une couche boxplot
3   labs(title = "Boxplot du maximum d'ozone", x= "un joli titre pour l'axe x", y = "Maximum d'ozone")
```



GGplot - Exemple: distribution d'une variable quantitative

Moche ? Pensez à `theme_bw()` (black & white)







```
1 ggplot(ozone, aes(y = maxO3)) + # création de l'objet ggplot, en spécifiant ce qu'on veut en y
2   geom_boxplot() + # ajout d'une couche boxplot, classes plus grossières
3   labs(title = "Boxplot du maximum d'ozone", y = "Maximum d'ozone") +
4   theme_bw()
```



Distribution d'une variable qualitative (1/2)

Le camembert c'est bon, mais *seulement en fromage*. SINON CA PUE TROP.


Quelle classe est la plus représentée ?




Distribution d'une variable qualitative (2/2)

Alternative: graphiques en barre

► Code




► Code




Effet d'une / deux variable(s) sur une variable quanti

```
1 ggplot(ozone, aes(x = T9, y= maxO3)) +  
2   geom_point() + # ajout points  
3   geom_smooth(method = "lm", se = FALSE) + # Ajout a  
4   theme_bw()
```




```
1 ggplot(ozone, aes(x = T9, y= maxO3, color = vent)) +  
2   #par direction du vent  
3   geom_point() + # ajout points  
4   geom_smooth(method = "lm", se = FALSE) + # Ajout a  
5   theme_bw()
```



Effet d'une / deux variable(s) quali sur une variable quanti (1/2)

```
1 ggplot(ozone, aes(x = vent,  
2                   y= maxO3,  
3                   fill=vent,  
4                   col=vent)) + # dans aes: ce qui DE  
5   geom_boxplot(outlier.shape=NA,alpha=0.4) + # alpha  
6   geom_point(position = position_jitter(width = 0.05  
7   # points, avec perturbation horizontale pour facil  
8   theme_bw() +  
9   labs(title = "Effet du vent sur le max d'ozone")
```



Effet de deux variable(s) quali sur une variable quanti (2/2)

Quid d'une interaction potentielle vent pluie ?

Point code : La fonction `%>%` de `dplyr` permet de passer des arguments en chaîne dans des fonctions. Par ex.:


```
1 x <- 1:3
2 max(x)
```

[1] 3

```
1 library(dplyr) # permet d'utiliser %>%
2 x %>% max # equivaut à max(x)
```


[1] 3

► Code




Des visualisations vers les tests statistiques

Les visus précédentes nous ont permis d'intuiter certaines tendances.



Peut-on les généraliser ? Rappel:



C'est toute la question des *tests statistiques*.

Principes et applications des tests statistiques

De la question aux tests

- On dispose de multiples variables, toutes présentant potentiellement un intérêt

```
1 colnames(ozone)
```

```
[1] "maxO3" "T9"    "T12"   "T15"   "Ne9"   "Ne12"  "Ne15"  "Vx9"
[9] "Vx12"  "Vx15"  "maxO3v" "vent"  "pluie"
```

- Ici une variable particulière nous intéresse (c'est un *choix* ; guidé par la littérature scientifique / les politiques publiques etc.): maxO3 (car étant clé pour la pollution de l'air). C'est la **variable réponse**

On peut se poser plusieurs questions:

- Effet du vent sur le max d'ozone ?
- Le temps sec/pluvieux influence-t-il le max d'ozone ? De la même manière selon les différentes directions du vent ?

Objectif : Généraliser (inférer) au-delà des données de l'échantillon

Problème : Comment gérer l'incertitude liée au fait qu'on a observé qu'une petite partie des données

Faisons d'abord un détour par la notion de distribution statistique et de loi de probabilité

Rappel sur la notion de distribution statistique / loi de probabilité

- **Définition :**


Une distribution statistique décrit comment les valeurs d'une variable se répartissent dans un ensemble de données.

- **Types de variables :**

- *Quantitatives* : mesurables (ex : taille des plantes).
- *Qualitatives* : catégories (ex : variétés de cultures).

En théorie, une distribution peut s'approcher d'une loi de probabilité.

Un exemple classique de loi de probabilité que vous connaissez probablement : la loi normale.



Interprétation probabiliste


- La probabilité qu'une variable aléatoire appartienne à un intervalle donné est proportionnelle à la surface sous la courbe de distribution pour cet intervalle.

Décrire une loi de probabilité

Il existe de beaucoup de lois de probabilités, qu'on peut décrire via différents paramètres.

Quelques paramètres descriptifs d'une loi


- **Tendance centrale :**
 - Moyenne : la "valeur attendue".
 - Médiane : la valeur au milieu de la distribution.
 - Mode : la valeur la plus fréquente.
- **Dispersion :**
 - Variance / écart-type
 - IQR / étendue



Loi normale et règle des 68-95-99

- **Loi normale :** Distribution en forme de cloche centrée autour de la moyenne.
- **Règle 68-95-99 :**
 - 68% des données se trouvent à ± 1 écart-type (σ) de la moyenne.
 - 95% à ± 2 écarts-types.
 - 99.7% à ± 3 écarts-types.

Illustration de la règle 68-95-99



Rappel: Théorème central limite

La moyenne $\bar{X}$ de n valeurs issues d'une variable X de loi quelconque, de moyenne μ et de variance σ^2 , suit la loi (si $n > 30$ ou $X \sim \mathcal{N}$)

$$\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n) \quad \text{et donc} \quad \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim \mathcal{N}(0, 1)$$

- En pratique, σ^2 rarement connu, et donc doit être estimé à partir de l'échantillon
- $\implies$ augmente un peu l'incertitude $\implies$ utilisation d'une loi de Student $(n - 1)$ degrés de liberté (plutôt qu'une loi normale) : $\frac{\bar{X} - \mu}{\sqrt{S^2/n}} \sim \mathcal{T}(n - 1)$

D'où l'intervalle de confiance de μ au niveau de confiance 95%:

$$\left[\bar{x} - \frac{s}{\sqrt{n}} t_{1-\alpha/2}(n - 1) ; \bar{x} + \frac{s}{\sqrt{n}} t_{1-\alpha/2}(n - 1) \right]$$

```
1 t.test(ozone$max03)
```

One Sample t-test

```
data: ozone$max03
t = 33.905, df = 111, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 85.02578 95.58136
sample estimates:
mean of x
90.30357
```

```
1 x <- ozone$max03
2
3 mean(x) - qt(0.975,df = 111)*sd(x)/sqrt(length(x))
```

[1] 85.02578

```
1 mean(x) + qt(0.975,df = 111)*sd(x)/sqrt(length(x))
```

[1] 95.58136

Intervalle de confiance vers test de conformité

- On suppose / connaît $\frac{\bar{X}-\mu}{\sqrt{S^2/n}} \sim \mathcal{T}(n-1)$.
- On peut maintenant tester si la moyenne est égale à une valeur particulière, par ex est-ce que $\mu = 100$?

A partir d'un échantillon x , on peut calculer $\bar{x}$ et s^2 et se demander si la valeur est typique d'une loi de Student à $n-1$ ddl.


Quelques définitions

- H_0 hypothèse nulle, $H_0 : \mu = 100$ vs H_1 hypothèse alternative, $H_1 : \mu \neq 100$
- **Statistique de test:** $\frac{\bar{X}-\mu}{\sqrt{S^2/n}}$: il s'agit de la valeur qu'on peut calculer à partir de l'échantillon, et qu'on suppose suivre une certaine loi sous H_0 : ici une loi de Student à $n-1$ ddl
- **p-value** du test: probabilité calculée sous H_0 , que la statistique de test soit plus extrême que la valeur observée Tobs

p-value: "Dans un monde où H_0 est vraie, la probabilité d'obtenir une valeur au moins aussi extrême pour la statistique de test est de p"

Si $p < 0.05$, on rejette l'hypothèse H_0 au seuil de 5%

Dans notre cas, $n = 112$, donc T est censée suivre une loi de Student à 111 ddl, sous H_0 :



```
1 t.test(ozone$maxO3, mu = 100)
```

One Sample t-test

```
data: ozone$maxO3
t = -3.6406, df = 111, p-value = 0.0004148
alternative hypothesis: true mean is not equal
to 100
95 percent confidence interval:
 85.02578 95.58136
sample estimates:
mean of x
90.30357
```

```
1 # MEME CHOSE
2 Tobs <- sqrt(112)*(mean(ozone$maxO3 )- 100)/(sd(ozone$maxO3))
3 2*pt(Tobs, 111)
```

```
[1] 0.0004147533
```


Pour une loi de Student à $n-1$ ddl, -3.64 est une valeur *peu probable* donc on rejette H_0 , au seuil de 5%.

Comparaison de 2 moyennes (1/2)

Question: le temps (sec/pluvieux) a-t-il un effet sur le max d'ozone ?

Réflexe: visu !

► Code



Passer de l'échantillon à n'importe quel jour induit de l'incertitude. Mais, il est plus facile de conclure qu'il y a une différence entre les deux moyennes *dans la population* si:

1. Les moyennes sont très différentes (🔥 vs 🌧️)
2. La variabilité du maximum d'ozone est faible au sein des jours pluvieux et au sein des jours secs
3. Il y a beaucoup de données

Comparaison de 2 moyennes (2/2)

On considère que les données de la sous-population 1 sont telles que $(X_{i1})_{1 \leq i \leq n_1} \sim \mathcal{N}(\mu_1, \sigma^2)$ et que les données de la sous-population 2 sont telles que $(X_{i2})_{1 \leq i \leq n_2} \sim \mathcal{N}(\mu_2, \sigma^2) \Rightarrow$ (pour l'instant) seules les moyennes peuvent être différentes

- H_0 **hypothèse nulle**, $H_0 : \mu_1 = \mu_2$ vs H_1 **hypothèse alternative**, $H_1 : \mu_1 \neq \mu_2$
- **Statistique de test**: $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\hat{\sigma}^2}{n_1} + \frac{\hat{\sigma}^2}{n_2}}}$
- Sous H_0 , T suit une loi de Student $n_1 + n_2 - 2$


Si les variances sont inégales, le test est différent $\implies$ tester l'égalité des variances avant de faire le test de comparaison de moyennes

Test de comparaison de 2 variances

- H_0 hypothèse nulle, $H_0 : \sigma_1^2 = \sigma_2^2$ vs H_1 hypothèse alternative, $H_1 : \sigma_1^2 \neq \sigma_2^2$

$$\iff H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1 \text{ contre } H_1 : \frac{\sigma_1^2}{\sigma_2^2} \neq 1$$

- Statistique de test: $F = \frac{S_1^2}{S_2^2}$
- Sous H_0 , F suit une loi de Fisher à $n_1 - 1$ et $n_2 - 1$ ddl



Mise en pratique

```
1 var.test(maxO3 ~ pluie, data = ozone, alternative = "two.sided")
```

F test to compare two variances

```
data: maxO3 by pluie
F = 0.35906, num df = 42, denom df = 68, p-value = 0.0005659
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.2108847 0.6338374
sample estimates:
ratio of variances
 0.3590605
```

```
1 # NOTEZ LE VAR.EQUAL
2 t.test(maxO3 ~pluie, data = ozone, alternative = "two.sided", var.equal = FALSE)
```

Welch Two Sample t-test

```
data: maxO3 by pluie
t = -6.3362, df = 109.88, p-value = 5.321e-09
alternative hypothesis: true difference in means between group Pluie and group Sec is not equal to 0
95 percent confidence interval:
 -36.02936 -18.86110
sample estimates:
mean in group Pluie    mean in group Sec
      73.39535         100.84058
```

Ici on rejette H_0 au seuil de 5%,
les variances sont différentes


Erreur et puissance d'un test

Décision d'un test prise pour la population ("il y a plus d'ozone les jours sec") alors qu'on n'observe qu'un échantillon

⇒ Décision incertaine, et deux erreurs possibles

- **Erreur de première espèce:** rejeter H_0 alors que celle-ci est vraie: faux positif
- **Erreur de deuxième espèce :** ne pas rejeter H_0 alors que celle-ci est fausse: faux négatif

En image (? qu'est-ce que H_0 ici ?):



un test est dit puissant si son erreur de 2ème espèce est petite. La **puissance d'un test** est la probabilité de rejeter H_0 et d'avoir raison

Puissance d'un test (1/2)

Question souvent posée Combien de données faut-il pour tester une différence entre 2 moyennes ?

Par ex.: combien de patients pour tester s'il y a une diff entre 2 médicaments pour faire baisser le taux de cholestérol ?

Rappel: de quoi est-ce que ça dépend ?

- ?
- ?
- ?

Reformuler la question

Combien faut-il de patients pour mettre en évidence une différence d'au moins 0.2g/l entre les 2 médicaments ?

Toujours pas possible 😞

MAAAAIS 😊

Puissance d'un test (2/2)

MAAAAAAIS 😊 si;

- on connaît la variance de la variable d'intérêt (ex. expériences antérieures montrent un écart-type de 0.4g/l) (*sd*)
- on veut détecter une différence donnée par ex toute $\text{diff} > 0.2\text{g/l}$ (*delta*)
- on veut détecter cette différence avec proba de 80% (*power*)

alors c'est possible 😊

```
1 power.t.test(delta= 0.2,  
2              sd = 0.4, power = .80)
```

Two-sample t test power calculation

```
n = 63.76576  
delta = 0.2  
sd = 0.4  
sig.level = 0.05  
power = 0.8  
alternative = two.sided
```

NOTE: n is number in **each** group

Analyse de variance à un facteur

Test de l'effet d'un facteur

Par ex. la direction du vent a-t-elle un effet sur le maximum d'ozone ?

Variable réponse quantitative, notée Y: maxO3

Variable explicative qualitative à I modalités (groupes): direction du vent


C'est le cadre de l'ANOVA (ANalysis Of VAriance)

maxO3	vent
87	Nord
82	Nord
92	Est
114	Nord
94	Ouest
80	Ouest

Réflexe ... ???

Visu!

► Code



Question de base modifiée en : la moyenne du maximum d'ozone est-elle la même pour chaque direction du vent ?

Problématique qui revient souvent

- L'effet de cultures intermédiaires est-il le même selon l'espèce/variété ?
- La présence de haies a-t-elle une influence sur la population d'auxiliaires de cultures ?
- Y a-t-il un effet de la variété sur le rendement du blé dans telle expérimentation ?
- etc. etc. etc.

De manière générale, l'ANOVA est le cadre d'analyse de **l'effet d'une variable qualitative** à *I* modalités (par ex. sol nu / moutarde / phacélie) sur une **variable quantitative**

Mais alors pourquoi parler d'Analyse de Variance si on veut comparer des moyennes ?

La réponse viendra avec les explications (et les mains dans le cambouis)

Mettons les mains dans le cambouis

Données & notations

vent	maxO3	Notation
Est	92	y_{11}
Est	121	y_{12}
Nord	87	y_{21}
Nord	82	y_{22}
Ouest	94	y_{31}
Ouest	80	y_{32}
Sud	90	y_{41}
...	...	...

y_{ij} valeur de Y pour l'individu j du groupe i

Moyenne du groupe i : $y_{i\bullet} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}$

Moyenne générale : $y_{\bullet\bullet} = \frac{1}{n} \sum_{i=1}^I \sum_{j=1}^{n_i} y_{ij}$

Comparaison de I moyennes

- Dans chaque groupe, on considère que les données suivent une loi $\mathcal{N}(\mu_i, \sigma^2)$

On considère le MEME σ^2 .

$Y_{1j} \sim \mathcal{N}(\mu_1, \sigma^2)$ peut s'écrire $Y_{1j} = \mu_1 + \varepsilon_{1j}$ avec $\varepsilon_{1j} \sim \mathcal{N}(0, \sigma^2)$

$Y_{2j} \sim \mathcal{N}(\mu_2, \sigma^2)$ peut s'écrire $Y_{2j} = \mu_2 + \varepsilon_{2j}$ avec $\varepsilon_{2j} \sim \mathcal{N}(0, \sigma^2)$

...

...


$Y_{Ij} \sim \mathcal{N}(\mu_I, \sigma^2)$ peut s'écrire $Y_{Ij} = \mu_I + \varepsilon_{Ij}$ avec $\varepsilon_{Ij} \sim \mathcal{N}(0, \sigma^2)$

$\Rightarrow$ On peut résumer tout ça dans un seul modèle:

$$\begin{cases} \forall i, j & Y_{ij} = \mu_i + \varepsilon_{ij} \\ \forall i, j & \mathcal{L}(\varepsilon_{ij}) = \mathcal{N}(0, \sigma^2) \\ \forall (i, j) \neq (i', j') & \text{cov}(\varepsilon_{ij}, \varepsilon_{i'j'}) = 0 \end{cases}$$


Deux définitions du modèle

Si Y_{ij} est la valeur de la réponse du j^{eme} individu ($j = 1, \dots, n_i$) du i^{eme} groupe ($i = 1, \dots, I$):



$$\begin{cases} \forall i, j & Y_{ij} = \mu_i + \varepsilon_{ij} \\ \forall i, j & \mathcal{L}(\varepsilon_{ij}) = \mathcal{N}(0, \sigma^2) \\ \forall (i, j) \neq (i', j') & cov(\varepsilon_{ij}, \varepsilon_{i'j'}) = 0 \end{cases}$$

I paramètres: les μ_i



$$\begin{cases} \forall i, j & Y_{ij} = \mu + \alpha_i + \varepsilon_{ij} \\ \forall i, j & \mathcal{L}(\varepsilon_{ij}) = \mathcal{N}(0, \sigma^2) \\ \forall (i, j) \neq (i', j') & cov(\varepsilon_{ij}, \varepsilon_{i'j'}) = 0 \end{cases}$$

$I + 1$ paramètres: l'effet moyen μ et les I coefficients α_i (effet du niveau i)

On doit avoir $\forall i, \mu + \alpha_i = \mu_i$ besoin de **contraintes**

Estimer les paramètres du modèle

On minimise les écarts entre observations (Y_{ij}) et prédictions par le modèle $\hat{Y}_{ij}$.

On minimise le **critère des moindres carrés ordinaires** (?: pourquoi carré ² ?)

$$SCER = \sum_{i=1}^I \sum_{j=1}^{n_i} (Y_{ij} - \hat{Y}_{ij})^2 = \sum_{i=1}^I \sum_{j=1}^{n_i} (Y_{ij} - (\hat{\mu} + \hat{\alpha}_i))^2$$

$$\text{SCER minimal quand } \forall i, \hat{\mu} + \hat{\alpha}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij} = Y_{i\bullet}$$

Contraintes classiques:

- Un niveau particulier comme référence: $\alpha_1 = 0 \Rightarrow \hat{\mu} = Y_{1\bullet}$ et $\forall i, \hat{\alpha}_i = Y_{i\bullet} - Y_{1\bullet}$
- la moyenne des moyennes par groupe comme référence: $\sum_{i=1}^I \alpha_i = 0 \Rightarrow \hat{\mu} = \frac{1}{I} \sum_{i=1}^I Y_{i\bullet}, \forall i, \hat{\alpha}_i = Y_{i\bullet} - \hat{\mu}$

Exemple pour clarifier

groupe 1	groupe 2	groupe3	
$y_{11} = 6$	$y_{21} = 2$	$y_{31} = 3$	
$y_{12} = 9$	$y_{22} = 4$	$y_{32} = 1$	
$y_{13} = 6$	$y_{22} = 3$		
$y_{1\bullet} = 7$	$y_{2\bullet} = 3$	$y_{3\bullet} = 2$	$y_{\bullet\bullet} = 4.25$

- Avec traitement 1 comme référence : $\hat{\mu} = 7$; $\hat{\alpha}_1 = 0$; $\hat{\alpha}_2 = -4$ et $\hat{\alpha}_3 = -5$
- $\sum_{i=1}^I \alpha_i = 0$: $\hat{\mu} = \frac{1}{3}(7 + 3 + 2) = 4$; $\hat{\alpha}_1 = 3$; $\hat{\alpha}_2 = -1$ et $\hat{\alpha}_3 = -2$

Important

Le choix de la contrainte impacte FORTEMENT l'interprétation

1. $\sum_i \alpha_i = 0$, la comparaison est faite par rapport à la moyenne des moyennes par modalité
2. $\alpha_1 = 0$, la comparaison est faite par rapport à un niveau de ref (*moins intuitif, et pas pratique quand présence d'interactions*)

Certaines fonctions de R par défaut utilisent la contrainte 2. !

Comparez les sorties de ces différentes lignes de code...

```
1 #lm par défaut
2 coef( lm(maxO3 ~ pluie,
3         data= ozone) )
```

(Intercept)	pluie1
pluieSec	
73.39535	
27.44523	

```
1 #lm en spécifiant le contraste
2 coef(lm(maxO3 ~ pluie,
3         data = ozone,
4         contrasts = list(pluie= "contr.sum")))
```

(Intercept)	pluie1
87.11796	-13.72262

```
1 # LinearModel prémâche le travail
2 LinearModel(maxO3 ~ pluie,
3             data= ozone)$Ttest
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	87.12	2.42	36.01	0
pluie - Pluie	-13.72	2.42	-5.67	0
pluie - Sec	13.72	2.42	5.67	0

Variance résiduelle

Valeurs prédites: $\hat{y}_{ij} = \hat{\mu} + \hat{\alpha}_i = y_{i\bullet}$


Erreurs d'ajustement ou résidus : $\hat{\varepsilon}_{ij} = y_{ij} - \hat{y}_{ij} = y_{ij} - y_{i\bullet}$

Estimateur de la variabilité résiduelle σ^2 :

$$\hat{\sigma}^2 = \frac{\sum_{ij} (Y_{ij} - Y_{i\bullet})^2}{n - I} = \frac{\sum_{ij} \hat{\varepsilon}_{ij}^2}{n - I} \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2$$

$n - I$ degrés de liberté sont associés à la somme des carrés des résidus du modèle.

Décomposition de la variabilité



Equation d'analyse de la variance

$$\underbrace{\sum_{i,j} (Y_{ij} - Y_{..})^2}_{SC_T} = \underbrace{\sum_i (Y_{i.} - Y_{..})^2}_{SC_F} + \underbrace{\sum_{i,j} (Y_{ij} - Y_{i.})^2}_{SC_R}$$

Variabilité	totale	modèle	résiduelle
ddl	$n - 1$	$I - 1$	$n - I$

- Vous pouvez commencez à comprendre d'où vient le nom ANalysis Of **VA**riance



Indicateur de liaison : rapport de corrélation

$$\eta^2 = \frac{SC_{\text{modèle}}}{SC_{\text{total}}} = 1 - \frac{SC_{\text{résiduelle}}}{SC_{\text{total}}}$$

Expliqué à mon grand-père (ou presque): la proportion de variabilité du phénomène que mon modèle explique

Propriétés:

- $0 \leq \eta^2 \leq 1$ (obvious)
- $\eta^2 = 0 \Leftrightarrow SC_{\text{modèle}} = 0$
- $\eta^2 = 1 \Leftrightarrow SC_{\text{modèle}} = SC_{\text{total}}$



Deux rapports de corrélation différents pour des $Y_{i\bullet}$ identiques.

Inférence: test global

Rappel de l'objectif: y a-t-il un effet du facteur sur Y ?

→ La variabilité de Y est-elle expliquée par le facteur groupe ? Ou bien peut-on considérer que les données proviennent d'une même loi $\mathcal{N}(\mu, \sigma^2)$?

Hypothèses:

$$H_0 : \forall i, \mu_i = \mu$$

$\Leftrightarrow$

$$H_0 : \forall i, \alpha_i = 0$$

$$H_1 : \exists i / \mu_i \neq \mu$$

$$H_1 : \exists i / \alpha_i \neq 0$$

$$\text{On a : } \mathbb{E} \left(\frac{SC_{mod}}{I-1} \right) = \sigma^2 + \frac{1}{I-1} \sum_{i=1}^I n_i \alpha_i^2 \quad ; \quad \mathbb{E} \left(\frac{SC_R}{n-I} \right) = \sigma^2$$

- **Statistique de test :** $F_{obs} = \frac{SC_{mod}/(I-1)}{SC_R/(n-I)}$
- **Loi de F_{obs} sous H_0 :** $\mathcal{L}(F_{obs}) = \mathcal{F}_{n-I}^{I-1}$




Table d'analyse de variance: décomposition de variabilité et test

- Ce qui est souvent reporté dans le cadre d'une ANOVA

Variabilité	Somme Carrés	ddl	Carré moyen	F_{obs}
Facteur	$\sum_i n_i (Y_{i\bullet} - Y_{\bullet\bullet})^2$	$I - 1$	$\frac{SC_F}{I - 1}$	$\frac{CM_F}{CM_R}$
Résiduelle	$\sum_{i,j} (Y_{ij} - Y_{i\bullet})^2$	$n - I$	$\frac{SC_R}{n - I}$	
Totale	$\sum_{i,j} (Y_{ij} - Y_{\bullet\bullet})^2$	$n - 1$		

```
1 library(FactoMineR)
2 LinearModel(maxO3 ~vent, data = ozone)
```

Call:

```
LinearModel(formula = maxO3 ~ vent, data = ozone)
```

Residual standard error: 27.32 on 108 degrees of freedom

Multiple R-squared: 0.08602

F-statistic: 3.388 on 3 and 108 DF, p-value: 0.02074


AIC = 744.8 BIC = 755.7

Ftest

	SS	df	MS	F value	Pr(>F)
vent	7586	3	2528.69	3.3881	0.02074
Residuals	80606	108	746.35		

Ttest

Estimate	Std. Error	t value	Pr(> t)
----------	------------	---------	----------



Inférence: test de conformité d'un coefficient (1/2)

Si on rejette l'hypothèse $H_0 : \forall i, \alpha_i = 0$, on veut savoir quels α_i sont différents de 0

La valeur de $\hat{\alpha}_i$ dépend de l'échantillon de données et donc l'estimateur $\hat{\alpha}_i$ est une variable aléatoire

$$\mathcal{L}(\hat{\alpha}_i) = \mathcal{N}(\alpha_i, \sigma_{\hat{\alpha}_i}^2) \iff \mathcal{L}\left(\frac{\hat{\alpha}_i - \alpha_i}{\sigma_{\hat{\alpha}_i}}\right) = \mathcal{N}(0, 1)$$

$$\mathcal{L}\left(\frac{\hat{\alpha}_i - \alpha_i}{\hat{\sigma}_{\hat{\alpha}_i}}\right) = \mathcal{T}_{n-I}$$

On peut donc construire le test de nullité d'un coefficient (α_1 par exemple):

Hypothèses : $H_0 : \alpha_1 = 0$ contre $H_1 : \alpha_1 \neq 0$

Statistique de test $\frac{\hat{\alpha}_1}{\hat{\sigma}_{\hat{\alpha}_1}}$

Loi de la statistique de test sous H_0 $\mathcal{L}\left(T_{obs} = \frac{\hat{\alpha}_1}{\hat{\sigma}_{\hat{\alpha}_1}}\right) = \mathcal{T}_{\nu=n-I}$

Décision par la p-value

Rq : connaissant la loi de $\hat{\alpha}_1$, on peut construire un intervalle de confiance:

$$\alpha_1 \in [\hat{\alpha}_1 - \hat{\sigma}_{\hat{\alpha}_1} \times t_{0.975}(n - I) ; \hat{\alpha}_1 + \hat{\sigma}_{\hat{\alpha}_1} \times t_{0.975}(n - I)]$$

Inference: test de conformité d'un coefficient (2/2)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	94.738210	3.053461	31.026504	1.290980e-55
vent - Est	10.861790	6.829425	1.590440	1.146587e-01
vent - Nord	-8.609178	4.621850	-1.862713	6.522029e-02
vent - Ouest	-10.038210	4.097207	-2.450013	1.589160e-02
vent - Sud	7.785599	5.205173	1.495743	1.376372e-01

```
1 library(FactoMineR)
2 res <- LinearModel(maxO3 ~vent, data = ozone)
3
4 res$Ttest
```

1		Estimate	Std. Error	t value	Pr(> t)
2	(Intercept)	94.738210	3.053461	31.026504	1.290980e-55
3	vent - Est	10.861790	6.829425	1.590440	1.146587e-01
4	vent - Nord	-8.609178	4.621850	-1.862713	6.522029e-02
5	vent - Ouest	-10.038210	4.097207	-2.450013	1.589160e-02
6	vent - Sud	7.785599	5.205173	1.495743	1.376372e-01

Test de comparaison 2 à 2

Autre stratégie : comparer toutes les paires de moyennes

Pb : on effectue beaucoup de tests $\Rightarrow$ risque de multiplier les erreurs en rejetant des hypothèses H_0 .

$\Rightarrow$ correction des tests: modifier le seuil $\alpha = 5\%$ et prendre $\alpha = \frac{5\%}{(\text{nb tests})}$

$\Rightarrow$ les tests sont peu puissants

```
1 library(FactoMineR)
2
3
4 res <- LinearModel(maxO3 ~vent, data = ozone)
5
6 meansComp(res, ~vent, adjust ="Bonferroni", graph =
```

\$adjMean


vent	emmean	SE	df	lower.CL	upper.CL
Est	105.6	8.64	108	83.7	127.5
Nord	86.1	4.91	108	73.7	98.6
Ouest	84.7	3.86	108	74.9	94.5
Sud	102.5	5.96	108	87.4	117.7

Confidence level used: 0.95
Conf-level adjustment: bonferroni method for 4 estimates

\$groupComp

\$groupComp\$Letters

Ouest	Nord	Sud	Est
"a"	"a"	"a"	"a"



Analyse des résidus du modèle


Rappel du modèle:

$$\begin{cases} \forall i, j & Y_{ij} = \mu_i + \varepsilon_{ij} \\ \forall i, j & \mathcal{L}(\varepsilon_{ij}) = \mathcal{N}(0, \sigma^2) \\ \forall (i, j) \neq (i', j') & \text{cov}(\varepsilon_{ij}, \varepsilon_{i'j'}) = 0 \end{cases}$$


- On a des hypothèses sur les *résidus* du modèle
- Les résidus, c'est ce qui n'est pas expliqué par le modèle. Donc pour les estimer, il faut *ajuster* le modèle

On peut ensuite vérifier les hypothèses du modèle

```
1 residus <- data.frame(residus=res$lmResult$residuals)
2 residus %>%
3   ggplot(aes(x=residus))+
4   geom_histogram(fill="lightblue", aes(y = after_stat(density))) +
5   theme_bw() +
6   labs(x = "Résidu", y = "Densité", title = "Histogramme des résidus")
```




```
1 residus %>%
2   ggplot(aes(y=residus,x=vent,fill=vent))+
3   geom_boxplot(alpha = .5)+
4   labs(title = "Boxplot des résidus par vent") +
5   theme_bw()
```



Régression linéaire simple

Liaison linéaire

```
1 ozone %>%
2   ggplot(aes(x = T9, y= maxO3)) +
3   geom_point() +
4   geom_smooth(method = "lm", se = FALSE) + # se= FALSE
5   # intervalles de confiance, method = "lm" ajustement
6   labs(title = "Lien entre température à 9°C et maxi
7   theme_bw()
```



Questions ?

- Influence de la température sur le max d'ozone ?
- A quel max d'ozone peut-on s'attendre s'il fait 19.5°C à 9h ?

Objectifs 🎯

- Etudier qualitativement et quantitativement la dépendance d'une variable réponse quantitative Y en fonction d'une variable quantitative x
- La variable x permet-elle d'expliquer la variabilité de la variable Y?
- Prédire Y à partir de x

Un autre indice de liaison: le coefficient de corrélation linéaire

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

- $-1 \leq r_{xy} \leq 1$
- $r_{xy} = 0 \Leftrightarrow$ pas de liaison *linéaire* entre X et Y
- $r_{xy} \approx 1 \Leftrightarrow$ relation *linéaire* croissante entre X et Y
- $r_{xy} \approx -1 \Leftrightarrow$ relation *linéaire* décroissante entre X et Y

```
1 cor.test(ozone$max03, ozone$T9)
```

Pearson's product-moment correlation

data: ozone\$max03 and ozone\$T9

t = 10.263, df = 110, p-value < 2.2e-16

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

0.5904575 0.7832906

sample estimates:

cor

0.6993865

- $r_{xy} = 0.70 \Rightarrow$ corrélation assez forte (et significativement différente de 0, mais on verra ça plus tard)

Corrélation, causalité etc. (1/2)

- Une corrélation est un indicateur utile, mais à utiliser avec précaution

“Corrélation n’implique pas causalité”





Oui, mais... la présence d’une corrélation suppose généralement un lien

- Ex. on observe une corrélation entre A et B. Plusieurs cas existent.
- $A \Rightarrow B$ (ex.  $\Rightarrow$ cancer )
- $B \Rightarrow A$ (idem)
- $A \Rightarrow B$ et $ET B \Rightarrow A$ (ex.  et CO_2)
- Une variable C a été omise, et influence A et B. (ex.  (C) $\Rightarrow$  (A),  (C) $\Rightarrow$  (B),  $\Leftrightarrow$ )
- Corrélation purement fortuite (site [spurious correlations](#))

Corrélation, causalité etc. (2/2)







Ex. pour rigoler:



“Corrélation n’implique pas causalité”

Ok, mais cette affirmation ne doit pas servir à réfuter toute association constatée dans des données.

Quelques valeurs de corrélations



(Re)Mettons les mains dans le cambouis

Le modèle de régression linéaire simple s'écrit ainsi:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \stackrel{ind}{\sim} \mathcal{N}(0, \sigma^2),$$

avec


- x_i la valeur de la variable explicative pour l'observation i
- $i = 1, \dots, n$ le numéro d'individu, n le nombre total d'individus
- β_0 l'ordonnée à l'origine
- β_1 la pente de la droite, mesure de l'effet de la variable x
- σ^2 la variance

Estimation des paramètres

$$SCER = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Paramètres d'espérance:

- $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$
- $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$



```
1 res <- LinearModel(maxO3 ~ T9, data = ozone)
2 res$Ttest
```

	Estimate	Std. Error	t value
Pr(> t)			
(Intercept)	-25.607608	11.4551179	-2.235473
	2.740572e-02		
T9	6.312999	0.6151378	10.262740
	9.729952e-18		

Variance résiduelle:

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 ; \quad ddl_{\text{résiduelle}} = n - 2 ; \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2$$

Test de conformité

$$\mathcal{L}(\hat{\beta}_1) = \mathcal{N}(\beta_1, \sigma_{\beta_1}^2) \text{ avec } \sigma_{\beta_1}^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\implies \mathcal{L}\left(\frac{\hat{\beta}_1 - \beta_1}{\sigma_{\hat{\beta}_1}}\right) = \mathcal{N}(0, 1) \implies \mathcal{L}\left(\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}}\right) = \mathcal{T}_{n-2}$$

On peut donc construire le test de nullité de β_1 :

Hypothèses : $H_0 : \beta_1 = 0$ contre $H_1 : \beta_1 \neq 0$


Statistique de test : $\frac{\hat{\beta}_1}{\hat{\sigma}_{\hat{\beta}_1}}$ **Loi de la statistique de test sous H_0 :** $\mathcal{L}\left(T_{obs} = \frac{\hat{\beta}_1}{\hat{\sigma}_{\hat{\beta}_1}}\right) = \mathcal{T}_{\nu=n-2}$

Rq 1. : comme dans l'ANOVA, connaissant la loi de $\hat{\beta}_1$, on peut construire un intervalle de confiance:

$$\beta_1 \in \left[\hat{\beta}_1 - \hat{\sigma}_{\hat{\beta}_1} \times t_{0.975}(n-2) ; \hat{\beta}_1 + \hat{\sigma}_{\hat{\beta}_1} \times t_{0.975}(n-2) \right]$$

Rq 2. : on peut aussi tester β_0 mais cela a moins d'importance en pratique

Décomposition de la variabilité



$$\begin{aligned} \sum_{i=1}^n (Y_i - \bar{Y})^2 &= \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \\ SCT &= SCM + SCR \\ n - 1 &= 1 + n - 2 \end{aligned}$$

Table d'analyse de la variance

Source de variation	Somme des carrés	Degrés de liberté	Carré moyen	F
Modèle	SCM	1	$\frac{SCM}{1}$	$\frac{CMM}{CMR}$
Erreur	SCR	$n - 2$	$\frac{SCR}{n-2}$	
Total	SCT	$n - 1$		

Comparaison de SCM et SCT par le critère $R^2 = \frac{SCM}{SCT}$

Propriétés :

- $0 \leq R^2 \leq 1$
- $R^2 = 0 \Leftrightarrow SC_{\text{modèle}} = 0$
- $R^2 = 1 \Leftrightarrow SC_{\text{modèle}} = SC_{\text{total}}$

Explication claire du concept sur le [site](#) de Science Etonnante

```
1 res <- LinearModel(maxO3 ~T9, data= ozone)
2 res$Ftest
```

	SS	df	MS	F value	Pr(>F)	
T9	43138	1	43138	105.32	< 2.2e-16 ***	
Residuals	45053	110	410			

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'
	0.05	'.'	0.1	' '		1

Test du modèle

Hypothèses

- $H_0 : \beta_1 = 0, \Leftrightarrow$ le modèle n'a pas d'intérêt (x n'explique pas Y)
- $H_1 : \beta_1 \neq 0, \Leftrightarrow$ le modèle a un intérêt (x explique Y)

Stat de Fisher

$$F = \frac{SCM/1}{SCR/(n-2)}$$

Loi de F sous H_0 : $\mathcal{L}(F) = \mathcal{F}_{n-2}^1$

Prédiction et intervalle de confiance


Pour une valeur de x_0 particulière, on peut maintenant prédire Y :

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

Prédiction de la valeur moyenne de Y pour un x_0 particulier

$$\mathbb{E}(\hat{Y}_0|x_0) \sim \mathcal{N}(Y_0, \sigma \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}})$$

► Code




Différent de:

Prédiction d'une nouvelle valeur de Y pour un x_0 donné (notez le 1 supplémentaire dans la variance).

$$\hat{Y}_0 \sim \mathcal{N}(Y_0, \sigma \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}})$$




► Code



Validité du modèle

Vérification des hypothèses de départ:

- Normalité des résidus, stabilité de la variance, indépendance des résidus



Construction et sélection de modèle

Modéliser = Comprendre et prévoir

? Des exemples de modélisation que vous effectuez tous les jours ?

- Budget pour évènement \$ 🎂
- ⚙️ 👕 vs ❄️ ☕
- 📅

? Comment faites-vous ?

- Ex. estimation du budget d'une soirée d'anniversaire
- Vous listez les variables (👯 🍷 🍸 🎉 🧺 🍷 etc.)
- Vous éliminez celles qui sont négligeables (ex. 🧺 🍷)
- Vous quantifiez l'effet des variables restantes

Les statistiques permettent de faire cela avec des phénomènes complexes, en partant de données collectées.

Exemple de problématiques

- Prévoir la sévérité d'une maladie fongique en fonction de la météo (P/ETP/T°) et de l'itk (gestion des résidus, sensibilité variétale etc;)
- Prédire les potentiels de rendements futurs du soja en France
- Potentiel de production éolien en fonction des conditions météorologiques

Objectifs:

- *Comprendre* quelles variables ont une influence sur une variable quanti
- *Prévoir* les valeurs de la variable réponse dans de nouvelles conditions

Régression simple vs multiple


- En régression simple, on ne considèrerait *qu'une* seule variable explicative
- En régression multiple, on en considère *plusieurs* (p)

$$\text{Réponse} = f(\text{var1}, \text{var}_2, \dots, \text{var}_p) = \underbrace{\text{var1} + \text{var}_2 + \dots + \text{var}_p}_{\text{régression linéaire}}$$

$$\begin{cases} \forall i = 1, \dots, n & \varepsilon_i \text{ i.i.d.}, \mathbb{E}(\varepsilon_i) = 0, \mathbb{V}(\varepsilon_i) = \sigma^2 \\ \forall i \neq k & \text{cov}(\varepsilon_i, \varepsilon_k) = 0 \end{cases}$$

Une variable quanti peut avoir un effet différent selon différentes modalités d'une quali

```
1 ozone %>%
2   ggplot(aes(x = T9, y = maxO3, color = vent))+
3   geom_point() +
4   geom_smooth(method = "lm", se = FALSE) +
5   labs(title = "Effet de T9 sur l'ozone selon les di
6   theme_bw() +
7   theme(text = element_text(size = 15))
```



Cela s'écrit ainsi:

$$MaxO3 \sim vent + T9 + vent:T9$$


$$MaxO3_{ij} \sim \mu + \begin{cases} \alpha_1 \text{ si vent d'est} \\ \alpha_2 \text{ si vent du nord} \\ \alpha_3 \text{ si vent d'ouest} \\ \alpha_4 \text{ si vent du sud} \end{cases} + \left(\beta + \begin{cases} \gamma_1 \text{ si vent d'est} \\ \gamma_2 \text{ si vent du nord} \\ \gamma_3 \text{ si vent d'ouest} \\ \gamma_4 \text{ si vent du sud} \end{cases} \right) \times T9_{ij} + alea_{ij}$$
$$\begin{cases} \forall i, j & Y_{ij} = \mu + \alpha_i + (\beta + \gamma_i) \times x_{ij} + \varepsilon_{ij} \\ \forall i, j & \varepsilon_{ij} \text{ i.i.d. , } \mathbb{E}(\varepsilon_{ij}) = 0, \mathbb{V}(\varepsilon_{ij}) = \sigma^2 \\ \forall i, j & cov(\varepsilon_{ij}, \varepsilon_{i'j'}) = 0 \end{cases}$$

Interaction entre deux variables qualitatives

~~Définition courante~~: réaction réciproque de deux phénomènes l'un sur l'autre

Définition statistique : l'effet d'un facteur sur Y diffère selon les modalités de l'autre facteur

```
1 library(dplyr)
2
3 ozone %>%
4   group_by(vent, pluie) %>%
5   summarize(MOY = mean(maxO3)) %>%
6   ggplot(aes(x=vent, y=MOY, col=pluie, group=pluie))
7   geom_line() +
8   geom_point() +
9   labs("Interaction pluie:vent sur maxO3", x = "Dire
10  theme_bw()+
11  theme(text = element_text(size = 18))
```





Cela s'écrit ainsi:



$$MaxO3 \sim vent + pluie + vent:pluie$$
$$MaxO3_{ijk} \sim \mu + \begin{cases} \alpha_1 \text{ si vent d'est} \\ \alpha_2 \text{ si vent du nord} \\ \alpha_3 \text{ si vent d'ouest} \\ \alpha_4 \text{ si vent du sud} \end{cases} + \begin{cases} \beta_1 \text{ si pluie} \\ \beta_2 \text{ si sec} \end{cases} + \begin{cases} \alpha\beta_{11} \text{ si vent d'est ET pluie} \\ \alpha\beta_{12} \text{ si vent d'est ET sec} \\ \alpha\beta_{21} \text{ si vent du nord ET pluie} \\ \dots \alpha\beta_{42} \text{ si vent du sud ET sec} \end{cases} + alea_{ijk}$$
$$\begin{cases} \forall i, j, k & Y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + \varepsilon_{ijk} \\ \forall i, j, k & \varepsilon_{ijk} \text{ i.i.d. , } \mathbb{E}(\varepsilon_{ijk}) = 0, \mathbb{V}(\varepsilon_{ijk}) = \sigma^2 \\ \forall i, j, k & cov(\varepsilon_{ijk}, \varepsilon_{i'j'k'}) = 0 \end{cases}$$

Quatres types d'effet possibles

► Code



► Code



Le(s) modèle(s) linéaire(s)

Le modèle linéaire peut souvent être adapté à des problèmes issu du vivant, modulo quelques points de vigilance

Réponse	Variable(s) explicative(s)	Méthode
Var. quantitative	1 var. quantitative	régression linéaire simple
Var. quantitative	1 var. qualitative à I modalités	analyse de variance à 1 facteur (rq: si $I = 2$ équivaut à comparaison de 2 moyennes)
Var. quantitative	p var. quantitatives	régression linéaire multiple
Var. quantitative	K var. qualitatives	analyse de variance à K facteurs
Var. quantitative	var. quantitatives et qualitatives	analyse de covariance
Var. qualitative (2 catégories)	var. quantitatives et qualitatives	régression logistique
Var. qualitative (K catégories)	var. quantitatives et qualitatives	régression multinomiale

(Re-Re)mettons les mains dans le cambouis

$$\begin{cases} \forall i = 1, \dots, n & Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_p x_{ip} + \varepsilon_i \\ \forall i = 1, \dots, n & \varepsilon_i \text{ i.i.d. , } \mathbb{E}(\varepsilon_i) = 0, \mathbb{V}(\varepsilon_i) = \sigma^2 \\ \forall i \neq k & \text{cov}(\varepsilon_i, \varepsilon_k) = 0 \end{cases}$$

(p+1) paramètres à estimer + 1 paramètre de variance σ^2

Matriciellement : $Y = X\beta + E$ avec $\mathbb{E}(E) = 0, \mathbb{V}(E) = \sigma^2 Id$

$$\begin{pmatrix} Y_1 \\ \vdots \\ Y_i \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ \vdots & & \vdots & & \vdots \\ 1 & x_{i1} & x_{i2} & & x_{ip} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_i \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Rq: ANOVA et ANCOVA peuvent aussi s'écrire sous cette forme.

ANOVA

$$\begin{cases} \forall i, j, k & Y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + \varepsilon_{ijk} \\ \forall i, j, k & \varepsilon_{ijk} \text{ i.i.d. , } \mathbb{E}(\varepsilon_{ijk}) = 0, \mathbb{V}(\varepsilon_{ijk}) = \sigma^2 \\ \forall i, j, k & \text{cov}(\varepsilon_{ijk}, \varepsilon_{i'j'k'}) = 0 \end{cases}$$

ANCOVA

$$\begin{cases} \forall i, j & Y_{ij} = \mu + \alpha_i + (\beta + \gamma_i) \times x_{ij} + \varepsilon_{ij} \\ \forall i, j & \varepsilon_{ij} \text{ i.i.d. , } \mathbb{E}(\varepsilon_{ij}) = 0, \mathbb{V}(\varepsilon_{ij}) = \sigma^2 \\ \forall i, j & \text{cov}(\varepsilon_{ij}, \varepsilon_{i'j'}) = 0 \end{cases}$$

Estimation des paramètres du modèle

Critère des moindres carrés: estimer les paramètres en minimisant la somme des carrés des écarts entre observations et prévisions par le modèle

$$Y \approx X\beta$$

$$X'Y \approx X'X\beta$$

$$\hat{\beta} = (X'X)^{-1}X'Y \text{ si } X'X \text{ est inversible}$$

Propriétés $\mathbb{E}(\hat{\beta}) = \beta$; $\mathbb{V}(\hat{\beta}) = (X'X)^{-1}\sigma^2$

La variance des résidus σ^2 est estimée par:

$$\hat{\sigma}^2 = \frac{\sum_i (Y_i - \hat{Y}_i)^2}{\text{nb données} - \text{nb paramètres estimés à partir des données}} \quad \mathbb{E}(\hat{\sigma}^2) = \sigma^2$$

Décomposition de la variabilité (bis)

$$\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\text{Variabilité totale}} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\text{modèle}} + \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\text{résiduelle}}$$

Pourcentage de variabilité de Y expliquée par le modèle: $R^2 = \frac{SC_{\text{modele}}}{SC_{\text{totale}}}$

Propriétés: $R^2 \in [0, 1]$.

La variabilité du modèle peut être décomposée par variable de 2 façons:

- en calculant la variabilité expliquée par chaque variable les unes après les autres (pb : la variabilité d'une variable dépend de l'ordre d'introduction des variables)
- en calculant la variabilité expliquée exclusivement par une variable (pb : la somme des variabilités de toutes les variables n'est pas égale à la variabilité du modèle)

Dans certains cas (données équilibrées), la variabilité du modèle se décompose parfaitement et ces 2 calculs donnent les mêmes résultats.

Exemple sur ozone

```
1 library(FactoMineR)
2 LinearModel(maxO3~T9+T12+T15+Ne9+Ne12+Ne15+Vx9+Vx12+Vx15+maxO3v+vent+pluie, data =ozone)
```

Call:

```
LinearModel(formula = maxO3 ~ T9 + T12 + T15 + Ne9 + Ne12 + Ne15 +
  Vx9 + Vx12 + Vx15 + maxO3v + vent + pluie, data = ozone)
```

Residual standard error: 14.51 on 97 degrees of freedom

Multiple R-squared: 0.7686

F-statistic: 23.01 on 14 and 97 DF, p-value: 8.744e-25

AIC = 613 BIC = 653.8

Ftest

	SS	df	MS	F value	Pr(>F)
T9	0.2	1	0.2	0.0011	0.97325
T12	376.0	1	376.0	1.7868	0.18445
T15	30.3	1	30.3	0.1439	0.70526
Ne9	1016.5	1	1016.5	4.8312	0.03033

```
1 # LinearModel(maxO3 ~. , data= ozone) ## Ecriture simplifiée
```

Test de l'effet d'une ou plusieurs variables

L'ensemble de variables $\mathcal{V}$ apporte-t-il des informations complémentaires intéressantes sachant que les autres variables sont déjà dans le modèle ?

Hypothèses : H_0 : "tous les coefficients associés aux variables de $\mathcal{V}$ sont égaux à 0" contre H_1 : "au moins un coefficient des variables $\mathcal{V} \neq 0$ "

Statistique de test:
$$F_{obs} = \frac{SC_{\mathcal{V}}/ddl_{\mathcal{V}}}{SC_R/ddl_R} = \frac{CM_{\mathcal{V}}}{CM_R}$$

Loi de la statistique de test: Sous H_0 , $\mathcal{L}(F_{obs}) = \mathcal{F}_{ddl_R}^{ddl_{\mathcal{V}}}$


Décision : $\mathbb{P}(\mathcal{F}_{ddl_{\mathcal{V}}}^{ddl_R} > F_{obs}) < 0.05 \implies \text{Rejet de } H_0$

- Revient à choisir entre le sous-modèle sans les variables $\mathcal{V}$ ou le modèle complet
- Si $\mathcal{V}$ contient tous les effets : revient à tester si R^2 est significativement différent de 0, i.e. si toutes les variables sont inutiles (versus au moins une utile)
- On somme les degrés de liberté associés à l'ensemble $\mathcal{V}$ sachant qu'1 variable quanti à 1 ddl, 1 variable quali à $I - 1$ ddl et une interaction a comme ddl le produit des ddl de chaque facteur

Sélection de variables

Sélection de modèle = trouver un compromis entre un modèle qui s'ajuste bien aux données et qui n'a pas "trop" de paramètres
(Rappel: \$ 🍰)

- Enorme littérature sur le sujet



- Souvent utilisé: sélection du modèle qui minimise l'AIC / BIC: compromis entre maximisation de la vraisemblance L (à quel point le modèle s'ajuste bien aux données) et le nb de paramètres

$$AIC = 2p - 2\ln(\hat{L})$$

$$BIC = p\ln(n) - 2\ln(\hat{L})$$

? A votre avis, quelle est la différence entre les 2 critères (✎ 📄 !)

Plusieurs stratégies

- Construction exhaustive de tous les sous-modèles (long et même impossible si trop de variables)
- Méthode descendante (backward): construire le modèle complet; supprimer la variable explicative la moins intéressante et reconstruire le modèle sans cette variable; itérer jusqu'à ce que toutes les variables explicatives soient intéressantes
- Méthode ascendante (forward): partir du modèle avec la variable la plus intéressante; ajouter la variable qui, connaissant les autres variables du modèle, apporte le plus d'information complémentaire; itérer jusqu'à ce qu'aucune variable n'apporte d'information intéressante
- Méthode stepwise: compromis entre les 2 méthodes ci-dessus

Exemple sur ozone: sélection de variables

```
1 library(FactoMineR)
2 LinearModel(maxO3 ~ ., data = ozone, selection = "bic")
```

Results for the complete model:

=====

Call:

```
LinearModel(formula = maxO3 ~ ., data = ozone, selection = "bic")
```

Residual standard error: 14.51 on 97 degrees of freedom

Multiple R-squared: 0.7686

F-statistic: 23.01 on 14 and 97 DF, p-value: 8.744e-25

AIC = 613 BIC = 653.8

Results for the model selected by BIC criterion:

=====

Call:

```
LinearModel(formula = maxO3 ~ T12 + Ne9 + Vx9 + maxO3v, data = ozone,
  selection = "bic")
```

Démarche en modélisation

1. Lister les variables potentiellement explicatives / prédictives
2. Visualiser
3. Sélectionner le sous-modèle (minimisation de l'AIC ou du BIC)
4. Interpréter les résultats (quelles variables ressortent ? Est-ce surprenant ? Est-ce en accord avec les connaissances sur le sujet ? Des confusions possibles ?)
5. Interpréter les coefficients (signe, valeur etc.)
6. (Prédire pour de nouvelles valeurs)

Codage et contraintes pour variables quali

La matrice de design X (dans $Y = X\beta + E$) a autant de lignes que d'individus. Pour les colonnes, c'est variable...

	Constante (μ ou β_0)	Variable quanti	Variable Quali	Interaction quali -quali
Représentation dans X	Une colonne de 1	Valeur de la variable	(I-1) colonnes par modalités de chaque variable à I modalités	(I-1)*(J-1) colonnes
Degrés de libertés (ddl)	1	1	I-1	(I-1)*(J-1)
Commentaires			Contrainte à poser sur les paramètres (le mieux est $\sum_{i=1}^I \alpha_i = 0$)	Contrainte à poser sur les paramètres (le mieux est $\forall i, \sum_j \alpha\beta_{ij} = 0$ et $\forall j, \sum_i \alpha\beta_{ij} = 0$)

Important

Le choix de la contrainte impacte FORTEMENT l'interprétation

- $\sum_i \alpha_i = 0$, la comparaison est faite par rapport à la moyenne des moyennes par modalité
- $\alpha_1 = 0$, la comparaison est faite par rapport à un niveau de ref (*moins intuitif, et pas pratique quand présence d'interactions*)

Certaines fonctions de R par défaut utilisent la contrainte 2. !

Comparez les sorties de ces différentes lignes de code...

<pre>1 #lm par défaut 2 coef(lm(maxO3 ~ pluie, 3 data= ozone))</pre>	<pre>1 #lm en spécifiant le contraste 2 coef(lm(maxO3 ~ pluie, 3 data = ozone, 4 contrasts = list(pluie= "contr.sum")))</pre>	<pre>1 # LinearModel prémâche le travail 2 LinearModel(maxO3 ~ pluie, 3 data= ozone)\$ttest</pre>
(Intercept) pluieSec 73.39535 27.44523	(Intercept) pluie1 87.11796 -13.72262	Estimate Std. Error t value Pr(> t) (Intercept) 87.12 2.42 36.01 0 pluie - Pluie -13.72 2.42 -5.67 0 pluie - Sec 13.72 2.42 5.67 0

Interprétation des résultats

- **Modèle sélectionné** $\Rightarrow$ Interprétation des résultats

2 situations

1. Idéale: données équilibrées
2. Difficile: données déséquilibrées

Remarques:

- Les plans d'expériences permettent d'avoir données équilibrées
- En ANOVA, on a souvent des données équilibrées

Décomposition de la variabilité : variables quali, données équilibrées

Quand les données sont équilibrées, la décomposition de la variabilité est parfaite:

$$\begin{aligned} \sum_{i,j,k} (y_{ijk} - y_{\bullet\bullet\bullet})^2 &= \sum_{i,j,k} \underbrace{(y_{i\bullet\bullet} - y_{\bullet\bullet\bullet})^2}_{\hat{\alpha}_i^2} + \sum_{i,j,k} \underbrace{(y_{\bullet j\bullet} - y_{\bullet\bullet\bullet})^2}_{\hat{\beta}_j^2} \\ &\quad + \sum_{i,j,k} \underbrace{(y_{ij\bullet} - y_{i\bullet\bullet} - y_{\bullet j\bullet} + y_{\bullet\bullet\bullet})^2}_{\widehat{\alpha\beta}_{ij}^2} + \sum_{i,j,k} \underbrace{(y_{ijk} - y_{ij\bullet})^2}_{\varepsilon_{ijk}^2} \end{aligned}$$

Quand les données sont équilibrées, les coefficients s'estiment simplement:

$$\begin{aligned} \hat{\mu} &= y_{\bullet\bullet\bullet} & \forall i, \hat{\alpha}_i &= y_{i\bullet\bullet} - y_{\bullet\bullet\bullet} \\ \forall j, \hat{\beta}_j &= y_{\bullet j\bullet} - y_{\bullet\bullet\bullet} & \forall i, j, \widehat{\alpha\beta}_{ij} &= y_{ij\bullet} - y_{i\bullet\bullet} - y_{\bullet j\bullet} + y_{\bullet\bullet\bullet} \end{aligned}$$


⇒ On quantifie parfaitement ce qui est expliqué par chaque variable ou interaction

Comparaison de moyennes ajustées


Moyennes ajustées = $\hat{\mu} + \hat{\alpha}_i$: Permet de s'affranchir de l'effet des autres variables

Comparaisons possibles 2 à 2, moyennant une correction de Bonferroni par ex.

```
1 data_choco <- read.csv("data/chocolat_2022.csv", sep
2 mod <- LinearModel(Sucree~Produit+Juge+Produit:Juge,
3 meansComp(mod,~Produit, adjust="bonferonni")
```



\$adjMean				
Produit	emmean	SE	df	lower.CL
upper.CL				
CoteOr_bio70	4.50	0.264	118	3.75
5.25				
CoteOr_bio85	2.42	0.275	118	1.63
3.20				
Equador72	3.88	0.264	118	3.12
4.63				
Lindt70	4.79	0.264	118	4.04
5.55				
Lindt78	4.29	0.264	118	3.54
5.05				



Lindt85	2.58	0.264	118	1.83
3.34				
Renere hio74	3	88	0 275	118 3 09

Prédictions

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_p x_{ip}$$

Prédire Y pour : (T12=19, Ne9=8, Vx9=1.2, maxO3v=70) et (T12=23, Ne9=10, Vx9=0.9, maxO3v=95)

Sur PC:

```
1 model <- LinearModel(maxO3 ~ ., data = ozone, selection = "bic")
2
3 xnew <- data.frame(T12=c(19,23), Ne9=c(8,10), Vx9=c(1.2,0.9), maxO3v=c(70,95))
4 predict(model,xnew,interval="pred")
```


	fit	lwr	upr
1	71.41544	42.90026	99.93063
2	85.92393	56.76803	115.07983

```
1 predict(model,xnew,interval="confidence")
```

	fit	lwr	upr
1	71.41544	64.86327	77.96761
2	85.92393	76.98627	94.86159

Analyse des résidus


- Les résidus sont la part du phénomène non-expliquée par le modèle
- On peut vérifier les hypothèses initiales du modèle



Levene's Test for Homogeneity of Variance
(center = median)

	Df	F value	Pr(>F)
group	3	1.5589	0.2036
	108		

- Test de Shapiro-Wilk de normalité des Résidus (Rq : la non-normalité n'est pas un pb tant que la distribution est symétrique)



Shapiro-Wilk normality test

data: res
W = 0.97117, p-value = 0.01587

Retour sur l'exemple ozone

- Maximum d'ozone : variable réponse
- Les variables de températures, nébulosité, vitesse de vent (quanti), et la direction et la pluie (quali) sont prises en compte
- On ne sait pas si les interactions entre variables quali et entre les variables quali et quanti sont négligeables $\implies$ on les met dans le modèle

```
LinearModel(maxO3 ~ (T9 + T12 + T15 + Ne9 + Ne12 + Ne15 + Vx9 + Vx12 + Vx15 + maxO3v + pluie + vent) * (pluie + vent),  
data=ozone, selection="bic")
```

Ce qui revient à écrire :

```
maxO3 ~ T9 + T12 + T15 + Ne9 + Ne12 + Ne15 + Vx9 + Vx12 + Vx15 + maxO3v + pluie + vent + T9:pluie + T12:pluie + T15:pluie +  
Ne9:pluie + Ne12:pluie + Ne15:pluie + Vx9:pluie + Vx12:pluie + Vx15:pluie + maxO3v:pluie + vent:pluie + T9:vent + T12:vent +  
T15:vent + Ne9:vent + Ne12:vent + Ne15:vent + Vx9:vent + Vx12:vent + Vx15:vent + maxO3v:vent
```

Résultat et sortie

Results for the complete model:

```
Call: LinearModel(formula = maxO3 ~ (T9 + T12 + T15 + Ne9 + Ne12 + Ne15 + Vx9 + Vx12 + Vx15 + maxO3v + pluie + vent) *  
(pluie + vent), data = ozone, selection = "bic")
```

Residual standard error: 14.54 on 56 degrees of freedom Multiple R-squared: 0.8658 F-statistic: 6.569 on 55 and 56 DF, p-value: 2.585e-11 AIC = 634 BIC = 786.2

Results for the model selected by BIC criterion:

```
Call: LinearModel(formula = maxO3 ~ T9 + T15 + Ne12 + Vx9 + maxO3v + vent + T9:vent + T15:vent, data = ozone, selection =  
"bic")
```

Residual standard error: 13.8 on 97 degrees of freedom Multiple R-squared: 0.7906 F-statistic: 26.16 on 14 and 97 DF, p-value: 8.082e-27 AIC = 601.8 BIC = 642.6

Interprétation des résultats

	SS	df	MS	F	value	Pr(>F)
T9	606.2	1	606.2	3.1841	0.0775	.
T15	252.8	1	252.8	1.3278	0.2520	
Ne12	2107.0	1	2107.0	11.0664	0.0012	**
Vx9	1657.3	1	1657.3	8.7046	0.0040	**
maxO3v	5160.8	1	5160.8	27.1060	<2e-16	***
vent	12.5	3	4.2	0.0218	0.9956	
T9:vent	2587.1	3	862.4	4.5294	0.0051	**
T15:vent	3722.1	3	1240.7	6.5165	0.0005	***
Residuals	18468.3	97	190.4			

 Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

On peut dire (à partir des effets significatifs) qu’il y a, sur le max d’O3:

- des effets de nébulosité de vitesse de vent, du maximum d’O3 de la veille
- des effets de la direction du vent et des températures mais à travers les interactions : la direction du vent modifie l’effet de la T° (i.e. amplifie l’effet de la T° ou la diminue selon la direction du vent) sur max O3

On peut aussi dire (à partir des absences d’effets significatifs):

- la pluviométrie n’est pas un facteur déterminant qui influe sur le max d’O3
- une seule nébulosité (Ne12) est conservée dans le modèle : cela ne veut pas dire que les autres nébulosités n’ont pas d’effet (elles peuvent avoir un effet similaire). Idem pour la vitesse de vent.
- pour la T°, on a besoin des T° à 9h et à 15h pour mieux prévoir le maximum d’ozone. L’effet de la T° n’est pas exactement le même entre 9h et 15h (mais 12h n’est pas utile comme info)
- l’effet de la nébulosité est le même quelle que soit la direction du vent. Idem pour la vitesse du vent.

Interprétation des résultats (2/2)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.2063	13.7059	1.3284	0.1872
T9	1.8269	1.0238	1.7844	0.0775
T15	1.0200	0.8852	1.1523	0.2520
Ne12	-3.0132	0.9058	-3.3266	0.0012
Vx9	2.2213	0.7529	2.9504	0.0040
maxO3v	0.3467	0.0666	5.2063	0.0000
vent - Est	0.4734	17.0102	0.0278	0.9779
vent - Nord	3.2974	15.0356	0.2193	0.8269
vent - Ouest	-1.1250	14.0066	-0.0803	0.9361
vent - Sud	-2.6458	15.1489	-0.1747	0.8617
vent - Est : T9	-4.7442	2.1418	-2.2151	0.0291
vent - Nord : T9	6.1408	1.7014	3.6093	0.0005
vent - Ouest : T9	-0.9505	1.3455	-0.7064	0.4816
vent - Sud : T9	-0.4460	1.5222	-0.2930	0.7701
vent - Est : T15	3.6810	1.7967	2.0487	0.0432

- pour T9 et T15, $\beta \neq 0$
- **+** nébulosité, **-** max d'O3 (▲)
- **+** maximum d'O3 de la veille est grand, **+** maximum d'O3 du jour
- les jours de vents d'est et surtout du nord ont des max d'O3 supérieur aux jours de vents d'ouest et du sud
- les jours de vent du nord, l'effet de la T° à 9h est plus important (coef = 6.14); au contraire quand le vent vient de l'est. C'est l'inverse pour la T° à 15h
- Ainsi, quand le vent du nord, l'effet de la T° à 9h est particulièrement fort (donc s'il fait chaud à 9h quand le vent vient du nord, le max d'O3 risque d'être important)
- etc.

Démarche en modélisation (bis)

1. Lister les variables potentiellement explicatives / prédictives
2. Visualiser
3. Sélectionner le sous-modèle (minimisation de l'AIC ou du BIC)
4. Interpréter les résultats (quelles variables ressortent ? Est-ce surprenant ? Est-ce en accord avec les connaissances sur le sujet ? Des confusions possibles ?)
5. Interpréter les coefficients (signe, valeur etc.)
6. Prédire pour de nouvelles valeurs

Annexes

Le TCL, c'est PUISSANT

- Ce que dit le TCL, c'est que peu importe la distribution de base, les moyennes empiriques d'échantillons issues cette distribution auront une distribution normale centrée sur l'espérance de la distribution !

Une simulation rapide pour visualiser les choses

- Ex distribution $\chi_2(3)$
- On connaît la vraie moyenne de cette loi: 3

Mais dans la *vraie vie*, on aurait accès qu'à un échantillon de cette loi, par ex. de taille $n = 50$. Regardons comment évolue la distribution des moyennes empiriques en fonction de la taille de l'échantillon.

